

Robótica Agrícola com Visão Computacional para Monitoramento de Lavouras de Café

Rafael Pinto¹, Helga Balbi¹

¹Programa de Pós-Graduação em Ciência da Computação (PPCIC)
Centro Federal de Educação Tecnológica Celso Suckow da Fonseca (CEFET/RJ)
Rio de Janeiro – RJ – Brasil

rafael.pinto.1@aluno.cefet-rj.br

Abstract. *Brazilian coffee farming, the world's largest producer [Ordoñez-Avila and Fernández-Olivares 2024], faces growing labor shortages in farm monitoring tasks; coffee is absent from the 145 commercial robots cataloged by [Spagnuolo et al. 2025] and UAV-based yield studies are scarce [Barbosa et al. 2021]. This bibliographic review finds that terrestrial computer vision for coffee maturity classification and yield mapping already exists, but only coupled to the mechanical harvester itself [Bazame et al. 2021, Bazame et al. 2022]; the gap that remains is an autonomous platform capable of surveying the field before the harvest decision is made.*

Resumo. *A cafeicultura brasileira, maior produtora mundial de café [Ordoñez-Avila and Fernández-Olivares 2024], enfrenta escassez de mão de obra no monitoramento das lavouras; o café está ausente dos 145 robôs comerciais catalogados por [Spagnuolo et al. 2025] e estudos de quantificação de frutos na planta são escassos [Barbosa et al. 2021]. Esta revisão bibliográfica constata que a visão computacional terrestre para classificação de maturação e mapeamento de produtividade do café já existe, mas apenas acoplada à colhedora mecânica [Bazame et al. 2021, Bazame et al. 2022]; a lacuna remanescente é uma plataforma autônoma capaz de percorrer a lavoura antes da decisão de colher.*

1. Introdução

O café é uma cultura de elevada importância econômica, com o Brasil e a Colômbia ocupando, respectivamente, a primeira e a terceira posição entre os maiores produtores mundiais [Ordoñez-Avila and Fernández-Olivares 2024]. O setor enfrenta crescente escassez de mão de obra, pressionando a automação do monitoramento e da colheita [Miller et al. 2025]. Estudos voltados à estimativa de produtividade do café por meio de imagens aéreas são escassos na literatura especializada [Barbosa et al. 2021].

Nesse contexto, sistemas robóticos equipados com visão computacional são investigados para automatizar o monitoramento de lavouras. O café está completamente ausente entre os 145 robôs agrícolas comerciais de 123 empresas catalogados por [Spagnuolo et al. 2025], e os poucos sistemas terrestres já demonstrados especificamente para café — como o rover de monitoramento de

[Ordoñez-Avila and Fernández-Olivares 2024] — ainda não cobrem maturação e produtividade em conjunto, lacuna detalhada na Seção 3. A Figura 1 sintetiza os três pilares desta pesquisa.




Figura 1. Pilares desta pesquisa (elaboração própria).

O objetivo é identificar o estado da arte em robótica agrícola e visão computacional aplicados ao monitoramento de lavouras de café e delimitar lacunas técnicas ainda não respondidas, fundamentando o desenvolvimento de um sistema embarcado terrestre para estimativa de maturidade e produtividade do café em campo aberto.

2. Fundamentação Teórica

2.1. Maturação do Café e Desafios para a Percepção Visual

Países cafeicultores da América Latina dependem da modernização das lavouras para reduzir custos e ampliar a competitividade [Ordoñez-Avila and Fernández-Olivares 2024]. O monitoramento de plantas de café é realizado manualmente, sendo intensivo em trabalho, demorado e custoso em terrenos montanhosos [Wang et al. 2024]. Estudos que exploram o potencial de sistemas automatizados para estimativa de produtividade de lavouras cafeeiras são escassos na literatura especializada [Barbosa et al. 2021].

As características espectrais das plantas de café variam significativamente ao longo dos estágios fenológicos, o que dificulta o reconhecimento automático por imagens [Wang et al. 2024]. A banda RGB é mais eficaz na floração; combinações com infravermelho próximo (RGN) são superiores em outros períodos fenológicos [Wang et al. 2024]. Essa variabilidade fenológica exige abordagens adaptativas de análise de imagens em campo [Wang et al. 2024].

2.2. Fundamentos de Visão Computacional para Detecção de Frutos

Visão computacional oferece um método não destrutivo para estimativa de produtividade agrícola [Wang et al. 2024]. Combinações multiespectrais incorporam o infravermelho próximo e a borda vermelha (*red edge*), que indicam estágios fenológicos [Wang et al. 2024]. Redes Neurais Convolucionais (CNNs) atuam como *backbone* para extrair características multiescalares, dispensando a extração manual [Wang et al. 2024].

Na análise de imagens agrícolas, distinguem-se classificação, que atribui uma categoria à imagem inteira, e detecção, que localiza cada objeto por caixas delimitadoras (*bounding boxes*) [Ren et al. 2017]. Os de estágio único, como o YOLO, processam a imagem em uma única passagem, sendo adequados à inferência em tempo real [Redmon et al. 2016]. Os de dois estágios, como o Faster R-CNN, alcançam maior precisão a custo computacional superior; o desempenho é avaliado por F1-Score e mAP (*mean Average Precision*) [Ren et al. 2017].

2.3. Métodos para Avaliação de Maturação de Frutos

Abordagens tradicionais exploram parâmetros biofísicos como o índice de área foliar (LAI) e o diâmetro de copa, combinados com algoritmos de aprendizado de máquina [Barbosa et al. 2021]. Ao comparar cinco algoritmos sobre 144 árvores de *Coffea arabica* em Minas Gerais, [Barbosa et al. 2021] obtêm o melhor resultado com NEAT: MAPE de 31,75%. Essas abordagens evidenciam a viabilidade do aprendizado de máquina para análise de lavouras cafeeiras, mas a dependência de parâmetros coletados manualmente limita a escalabilidade [Barbosa et al. 2021].

Abordagens com aprendizado profundo superam essa limitação ao aprender representações diretamente das imagens, dispensando extração manual de características [Wang et al. 2024]. O *data augmentation* — rotação, espelhamento e ajuste de brilho — amplia a variabilidade e reduz o sobreajuste em conjuntos de imagens limitados [Ordoñez-Avila and Fernández-Olivares 2024]. A Tabela 1 sintetiza trabalhos que aplicam visão computacional ao café, ilustrando a variedade de plataformas, técnicas e métricas.

Tabela 1. Trabalhos com visão computacional aplicada ao café (elaboração própria).

Artigo	Tarefa	Técnica	Plataforma	Métrica
Wang et al. (2024)	Contagem de plantas	YOLOv9 + NMS dual	UAV multispectral	98,4%
Ordoñez-Avila e Fernández-Olivares (2024)	Deteção de ferrugem e grãos	Deep Learning	Rover terrestre	76%
Barbosa et al. (2021)	Predição de produtividade	NEAT, SVM, GBR	UAV RGB	MAPE 31,75%

3. Trabalhos Relacionados

Além dos artigos já apresentados na fundamentação teórica, foi conduzida uma busca complementar em 12/08/2026 com a expressão ("*coffee*" OR "*cafeeiro*") AND ("*computer vision*" OR "*deep learning*") AND ("*terrestrial*" OR "*ground robot*" OR "*rover*") AND ("*maturity*" OR "*ripeness*"). O objetivo era verificar se a combinação de plataforma terrestre, maturação e produtividade já havia sido resolvida por algum trabalho não coberto na revisão inicial. A busca retornou [Bazame et al. 2021] e [Bazame et al. 2022], do mesmo grupo (ESALQ/USP), que revisam substancialmente a lacuna discutida nesta seção.

[Ordoñez-Avila and Fernández-Olivares 2024] desenvolveram o trabalho terrestre mais próximo do recorte antes dessa busca: um rover com aprendizado profundo que monitora lavouras colombianas, detectando ferrugem e contando grãos com 76% de acerto, mas sem estimar maturação ou produtividade. [Quintero Lara et al. 2025] também combinam robótica e visão computacional na lavoura colombiana, porém para assistir fisicamente a colheita — a visão é sensor pontual de acionamento, não instrumento de monitoramento contínuo.

Os dois estudos que tratam de produtividade do café — [Wang et al. 2024] e [Barbosa et al. 2021] — operam a partir de imagens aéreas capturadas por VANT, não de uma plataforma terrestre. [Wang et al. 2024] atingem 98,4% de acerto na contagem de plantas com YOLOv9 e supressão dual de não-máximos, mas contam plantas inteiras, não frutos individuais, e a resolução de imagem aérea multiespectral não captura o estágio de maturação de cada fruto. [Barbosa et al. 2021] predizem produtividade a partir de LAI e diâmetro de copa extraídos de imagens RGB de VANT sobre 144 árvores, com o algoritmo NEAT alcançando o menor erro do conjunto (MAPE de 31,75%); os autores apontam a dependência de parâmetros biofísicos coletados manualmente como limite à escalabilidade do método, e a altura de voo do VANT impede a resolução necessária para avaliar a coloração do fruto individual, atributo central da maturação do café [Barbosa et al. 2021].

O par [Bazame et al. 2021, Bazame et al. 2022] é o que mais se aproxima do recorte proposto e exige uma reavaliação cuidadosa da lacuna. [Bazame et al. 2021] instalaram uma câmera no bocal de uma colhedora mecânica de café, gravando vídeo durante a colheita real de duas áreas comerciais em Minas Gerais. Um modelo YOLOv3-tiny classificou os frutos em três estágios de maturação — verde, cereja e passa — com mAP de 84% e F1-Score de 82%, resolvendo exatamente a limitação de resolução das imagens aéreas apontada acima. [Bazame et al. 2022] usaram essas mesmas detecções para construir mapas de produtividade ao longo das linhas de colheita, explicando 81% da variância de um mapa de referência. A combinação terrestre com classificação de maturação e mapeamento de produtividade que esta revisão originalmente hipotetizava como inexplorada está, portanto, parcialmente resolvida por esse par de trabalhos.

A lacuna remanescente é mais estreita do que a hipótese inicial, mas ainda real: o sistema de [Bazame et al. 2021, Bazame et al. 2022] depende fisicamente da colhedora mecânica, já em movimento durante a colheita, produzindo mapas necessariamente retrospectivos — a decisão de colher já foi tomada quando a imagem é capturada. Não há, nesse par de trabalhos, navegação autônoma que percorra a lavoura antes da colheita para informar essa decisão; essa capacidade já foi demonstrada por [Ordoñez-Avila and Fernández-Olivares 2024] com um rover independente, ainda que aplicada a doença e contagem de grãos. A Tabela 2 organiza os trabalhos por plataforma, autonomia e momento de operação.

Revisões mais amplas situam esse recorte num contexto geral, sem tratar do café. [Hernández et al. 2025] cobrem robótica agrícola reconfigurável com foco mecânico, não no processamento de imagem. [Xu et al. 2022, Colizzi et al. 2020] revisam IoT agrícola tratando a visão computacional como sensor genérico, sem os desafios fenológicos discutidos na Seção 2.

Em conjunto, esses trabalhos mostram que os componentes isolados do problema já existem separadamente: classificação de maturação em solo [Bazame et al. 2021], mapeamento de produtividade a partir dela [Bazame et al. 2022] e navegação autônoma independente da colhedora [Ordoñez-Avila and Fernández-Olivares 2024]. Nenhum, porém, os combina numa plataforma autônoma que opere antes da colheita. Essa é a lacuna refinada, discutida na Seção 4.

Tabela 2. Cobertura dos trabalhos aplicados ao café frente ao recorte proposto (elaboração própria).

Trabalho	Plataforma	Autônomo	Momento
Ordoñez-Ávila e Fernández-Olivares (2024)	Terrestre (ro-ver)	Sim	Pré-colheita
Quintero Lara et al. (2025)	Terrestre (braço)	Não	Durante co-lheita
Wang et al. (2024)	Aérea (VANT)	Sim	Pré-colheita
Barbosa et al. (2021)	Aérea (VANT)	Sim	Pré-colheita
Bazame et al. (2021, 2022)	Terrestre (colhedora)	Não	Durante co-lheita

4. Considerações Finais

Esta revisão bibliográfica reuniu evidências de três frentes. A primeira é a caracterização espectral e fenológica do café, que exige abordagens de imagem adaptativas ao longo do ciclo da planta [Wang et al. 2024]. A segunda são os métodos de detecção por aprendizado profundo, com o compromisso entre velocidade de estágio único (YOLO) e precisão de dois estágios (Faster R-CNN) já delimitado na literatura geral de visão computacional [Redmon et al. 2016, Ren et al. 2017]. A terceira são os trabalhos aplicados especificamente ao café, que cobrem contagem e produtividade por via aérea [Wang et al. 2024, Barbosa et al. 2021], classificação de maturação e mapeamento de produtividade acoplados à colhedora mecânica [Bazame et al. 2021, Bazame et al. 2022], e navegação terrestre autônoma para outras tarefas [Ordoñez-Avila and Fernández-Olivares 2024, Quintero Lara et al. 2025].

A hipótese inicial desta revisão — de que nenhum trabalho combina plataforma terrestre, maturação e produtividade — não se sustentou por completo: [Bazame et al. 2021, Bazame et al. 2022] já demonstram essa combinação com 84% de mAP na classificação e 81% de variância explicada no mapeamento. A lacuna que resiste a essa verificação é mais estreita: um sistema *autônomo*, independente da colhedora mecânica, que opere *antes* da colheita e informe a decisão de quando e onde colher, em vez de apenas documentar retrospectivamente o que já foi colhido. Essa navegação autônoma já foi demonstrada em outra tarefa da mesma cultura por [Ordoñez-Avila and Fernández-Olivares 2024], o que sugere que a integração — não a invenção de cada parte — é a contribuição em aberto.

O próximo passo desta investigação é o projeto de um protótipo terrestre autônomo. Ele deve combinar a classificação de maturação e a estimativa de produtividade já validadas por [Bazame et al. 2021, Bazame et al. 2022] com a capacidade de navegação independente de [Ordoñez-Avila and Fernández-Olivares 2024], permitindo o levantamento da lavoura em qualquer momento anterior à colheita. A validação de campo deve ser comparada aos parâmetros já estabelecidos por esse par de trabalhos (mAP de 84% na classificação e 81% de variância explicada no mapeamento).

Referências

- Barbosa, B. D. S., Ferraz, G. A. e. S., Costa, L., Ampatzidis, Y., Vijayakumar, V., and dos Santos, L. M. (2021). UAV-based coffee yield prediction utilizing feature selection and deep learning. *Smart Agricultural Technology*, 1.
- Bazame, H. C., Molin, J. P., Althoff, D., and Martello, M. (2021). Detection, classification, and mapping of coffee fruits during harvest with computer vision. *Computers and Electronics in Agriculture*, 183:106066.
- Bazame, H. C., Molin, J. P., Althoff, D., Martello, M., and Corrêdo, L. D. P. (2022). Mapping coffee yield with computer vision. *Precision Agriculture*, 23:2372–2387.
- Colizzi, L. et al. (2020). Introduction to agricultural IoT. In *Agricultural IoT and Decision Support for Precision Smart Farming*. Elsevier.
- Hernández, C. et al. (2025). Reconfigurable agricultural robotics: Control strategies, communication, and applications. *Computers and Electronics in Agriculture*.
- Miller, T., Mikiciuk, G., Durlík, I., Mikiciuk, M., Łobodzińska, A., and Śnieg, M. (2025). The IoT and AI in agriculture: The time is now—a systematic review of smart sensing technologies. *Sensors*, 25(12):3583.
- Ordoñez-Avila, J. L. and Fernández-Olivares, J. (2024). A mobile robot with deep learning for monitoring coffee farms. In *Proceedings of the LACCEI International Multi-Conference for Engineering, Education and Technology*.
- Quintero Lara, A. R., Prada, S. R., Vargas Rivera, D. A., and Gómez, L. D. (2025). Application of computer vision tools and robotics to assist in the harvesting activities of coffee crops in colombia. In *ASME International Mechanical Engineering Congress and Exposition (IMECE)*.
- Redmon, J., Divvala, S., Girshick, R., and Farhadi, A. (2016). You only look once: Unified, real-time object detection. In *Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition (CVPR)*, pages 779–788.
- Ren, S., He, K., Girshick, R., and Sun, J. (2017). Faster R-CNN: Towards real-time object detection with region proposal networks. *IEEE Transactions on Pattern Analysis and Machine Intelligence*, 39(6):1137–1149.
- Spagnuolo, M., Todde, G., Caria, M., Furnitto, N., Schillaci, G., and Failla, S. (2025). Agricultural robotics: A technical review addressing challenges in sustainable crop production. *Robotics*, 14(2):9.
- Wang, X., Zhang, C., Qiang, Z., Liu, C., Wei, X., and Cheng, F. (2024). A coffee plant counting method based on dual-channel NMS and YOLOv9 leveraging UAV multispectral imaging. *Remote Sensing*, 16(20).
- Xu, L., Gu, J., and Tian, Y. (2022). Review of agricultural IoT technology. *Artificial Intelligence in Agriculture*, 6:10–22.